

의료비 예측 및 위험군 분류

머신러닝 기반 분석 프로젝트

중 간 보 고 서

보고 일자	2025년 (중간 보고)
프로젝트 단계	Part 1~7 완료 / 잔여 약 1개월
사용 데이터	insurance.csv (1,338명)
분석 도구	Python, scikit-learn, SHAP, K-Means

* 본 보고서는 프로젝트 진행 현황을 점검하기 위한 중간 보고 문서입니다.

1. 프로젝트 개요 및 목표

1-1. 분석 배경 및 목적

본 프로젝트는 미국 건강보험 데이터(insurance.csv)를 기반으로 개인의 의료비를 예측하고, 고비용 위험군을 조기에 식별하는 머신러닝 모델을 개발하는 것을 목표로 합니다. 흡연, 나이, BMI 등 주요 변수가 의료비에 미치는 영향을 정량화하여 보험사와 의료 기관이 리스크를 사전에 관리할 수 있는 근거를 제공하고자 합니다.

1-2. 핵심 분석 목표

- 의료비(charges) 회귀 예측 모델 구축 및 최적 모델 선정
- 고비용 환자(상위 25%) 분류 모델 개발
- SHAP 기반 변수 중요도 해석 및 핵심 위험요인 도출
- K-Means 클러스터링을 통한 위험군 세분화
- 금연 시나리오 시뮬레이션을 통한 의료비 절감 효과 추정
- 흡연자 내부 고비용 세부 그룹 분석

2. 사용 데이터

2-1. 데이터셋 개요

구분	내용	비고
파일명	insurance.csv	Kaggle 공개 데이터셋
총 샘플 수	1,338명	결측치 없음
Train / Test	80% / 20% (1,070 / 268명)	random_state=42 고정
타겟 변수	charges (의료비, \$)	왜도 1.51, 우편포 분포

2-2. 원본 변수 (7개)

변수명	타입	범위/값	설명
age	수치형	18~64세	피보험자 나이
sex	범주형	male / female	성별
bmi	수치형	15.96~53.13	체질량지수 (비만 기준: 30 이상)
children	수치형	0~5명	부양 자녀 수
smoker	범주형	yes / no	흡연 여부 (핵심 위험요인)
region	범주형	4개 지역	northeast / northwest / southeast / southwest
charges	수치형 (Y)	\$1,122~\$63,770	연간 의료비 (예측 타겟)

2-3. 파생 변수 (5개, 분석 과정에서 생성)

파생 변수명	생성 방법	의미 및 목적
obese	BMI >= 30 이면 1	비만 여부 이진화
smoker_bin	smoker == 'yes' 이면 1	흡연 여부 이진화
smoker_obese	smoker_bin x obese	흡연+비만 복합 위험요인 상호작용
age_smoker	age x smoker_bin	고령 흡연자 의료비 급증 효과 포착
bmi_smoker	bmi x smoker_bin	흡연자 내 BMI 효과 포착

※ 데이터 전처리: 수치형 변수는 StandardScaler 표준화, 범주형 변수는 OneHotEncoder(drop='first') 적용. Train 기준으로 fit하고 Test에는 transform만 적용하여 데이터 누수를 방지하였습니다.

3. 분석 진행 현황

3-1. 분석 단계별 완료 현황

단계	파트	주요 내용	핵심 결과	상태
1	Part 1. 탐색적 분석 (EDA)	분포 확인, 상관관계 분석, 변수 시각화, 파생변수 생성	흡연자 의료비 3~4배 높음	완료 ○
2	Part 2. 모델 학습 및 비교	5개 모델 학습(선형3+트리2), 교차검증, 성능 비교	GradientBoosting 최우수	완료 ○
3	Part 3. 하이퍼파라미터 튜닝	RandomizedSearchCV로 RF, GB 최적화 (각 40회 탐색)	튜닝 후 성능 향상 확인	완료 ○
4	Part 4. SHAP 변수 중요도 분석	TreeSHAP 적용, Summary/Bar/Dependence Plot 시각화	age_smoker, smoker_obese 핵심	완료 ○
5	Part 5. K-Means 클러스터링	Elbow/Silhouette로 최적 K 탐색, PCA 2D 시각화	위험군 세분화 완료	완료 ○
6	Part 5-2. 이진 분류 모델	고비용 환자(상위 25%) 판별, ROC/PR Curve, Confusion Matrix	ROC-AUC 높은 성능 달성	완료 ○
7	Part 6. 금연 시뮬레이션	흡연자 금연 시나리오, 1인당 절감액 및 나이/BMI별 분석	평균 절감액 정량 추정 완료	완료 ○
8	Part 7. 흡연자 내부 세분화	흡연자 전용 GBM 모델, 고/저비용 그룹 비교 분석	고령+비만 흡연자 우선 개입 근거	완료 ○

3-2. 주요 분석 결과 요약

[회귀 모델 성능 비교]

모델	R ²	RMSE (\$)	MAE (\$)	MAPE (%)	CV 안정성	비고
LinearRegression	0.782	-	-	-	안정	
Ridge (alpha=10)	0.782	-	-	-	안정	
Lasso (alpha=10)	0.780	-	-	-	안정	
RandomForest (200)	0.860	-	-	-	안정	
GradientBoosting	0.873	-	-	-	안정	
RF_tuned (최적화)	-	-	-	-	안정	최우수
GB_tuned (최적화)	-	-	-	-	안정	

※ 정확한 수치는 실행 환경에 따라 미세 차이가 있을 수 있으며, 코드 실행 시 결과 셀에서 확인 가능합니다.

[SHAP 분석 핵심 결과]

- **age_smoker** (나이 x 흡연): 의료비 예측에서 가장 중요한 변수 — 고령 흡연자일수록 의료비 급증
- **smoker_obese** (흡연 x 비만): 두 위험요인 복합 시 의료비에 추가적인 상승 효과
- **bmi_smoker** (BMI x 흡연): 흡연자 내에서도 BMI가 높을수록 의료비 증가
- 단순 **smoker** 변수보다 파생 상호작용 변수들이 더 강한 예측력을 가짐

[클러스터링 및 분류]

- **K-Means**: 최적 클러스터 수 탐색 완료. 고위험군(고령+흡연+비만 복합)과 저위험군 명확히 세분화
- 이진 분류: 고비용 환자(상위 25%, 약 \$16,639 이상) 판별 — 높은 ROC-AUC 달성
- 분류 모델은 회귀 모델과 상호 보완적으로 활용 가능 (리스크 스크리닝 + 정확한 금액 예측)

[금연 시뮬레이션]

- 274명 흡연자 대상, 흡연 관련 파생변수 일괄 0 처리 후 재예측
- 1인당 평균 절감 효과 정량 추정 완료 — 나이가 많고 BMI가 높은 흡연자일수록 절감 폭 더 큼
- 고령+비만 흡연자 우선 개입 시 의료비 절감 효과 극대화 가능

4. 프로젝트 목표 부합 점검

당초 설정한 분석 목표에 대비하여 현재까지 진행된 내용을 평가합니다.

목표	달성 내용	달성도	비고
의료비 회귀 예측 모델 구축	5개 모델 비교, 하이퍼파라미터 튜닝까지 완료. R^2 0.87+ 달성	달성	
고비용 환자 분류 모델 개발	이진 분류 모델 구축 완료, 높은 AUC 달성	달성	
핵심 위험요인 도출 (변수 중요도)	SHAP + Permutation Importance 이중 검증. 상호작용 변수 핵심 확인	달성	
위험군 세분화 (클러스터링)	K-Means + PCA 시각화 완료, 고위험군 특성 도출	달성	
의료비 절감 효과 추정	금연 시뮬레이션으로 1인당 절감액 정량화, 대상군 세분화 완료	달성	
모델 해석 가능성 확보	SHAP waterfall로 개별 환자 의료비 원인 설명 가능 수준 달성	달성	
최종 보고서 및 시각화 정리	현재 코드 및 분석 완료. 보고서 정리 및 발표 자료 작성 필요	진행 중	잔여

4-1. 한계점 및 유의 사항

- 데이터 규모: 1,338명으로 실제 보험사 데이터 대비 소규모 — 일반화 한계 존재
- 변수 제한: 지역, 직업, 병력, 생활습관 등 추가 변수 부재로 설명력에 한계
- 시뮬레이션 한계: 금연 절감액은 모델 예측 기반 추정치이며, 실제 임상 결과와 차이 가능
- 모델 공정성: 성별, 지역 등에 따른 예측 편향 여부는 별도 점검 필요

5. 향후 일정 (잔여 약 1개월)

분석 코드는 모두 완성된 상태이며, 잔여 기간은 결과 정리, 보고서 고도화, 발표 준비에 집중합니다.

주차	기간	주요 작업	산출물
1주차	~ D+7	결과 수치 최종 확인 및 정리, 시각화 품질 개선 (그래프 해상도, 레이블 등), 핵심 수치 정확도 재검증	검증 완료 수치표, 개선된 시각화
2주차	D+8 ~ D+14	최종 보고서 초안 작성 (분석 배경, 방법론, 결과 해석, 한계점, 결론), 데이터 및 모델 설명 구체화	최종 보고서 초안 (Word/PDF)
3주차	D+15 ~ D+21	발표 자료(PPT) 제작: 배경/목표 -> 데이터 -> 분석 결과 -> 시사점 순 구성, 핵심 그래프 선별 삽입	발표 슬라이드 (PPT)
4주차	D+22 ~ 최종일	보고서 및 발표자료 최종 검토/수정, 발표 리허설, 피드백 반영 후 제출	최종 제출본 (보고서 + 발표자료)

5-1. 잔여 기간 세부 작업 계획

[1단계: 결과 정리 및 시각화 완성 (1주차)]

- 각 Part별 핵심 수치(R^2 , RMSE, AUC 등) 최종 확인 및 문서화
- 현재 코드에서 실행된 출력 결과를 정리하여 표 형태로 재구성
- 시각화 그래프 해상도 개선 (DPI 조정), 제목/레이블 한글화
- SHAP Summary Plot, Confusion Matrix 등 발표용 그래프 선별

[2단계: 최종 보고서 작성 (2주차)]

- 보고서 구성: 서론 > 데이터 > 방법론 > Part별 결과 > 종합 결론 > 한계점 및 향후 연구
 - 각 Part의 분석 의도와 방법론을 비전문가도 이해할 수 있는 수준으로 서술
 - SHAP, K-Means, 시뮬레이션 결과의 실제 의미 해석 강화
- 통계적 근거 보강: 주요 수치의 신뢰구간 또는 교차검증 결과 함께 제시
- 한계점 및 향후 연구 방향 서술 (더 큰 데이터셋, 추가 변수 확보 등)

[3단계: 발표 자료 제작 (3주차)]

- 발표 흐름: 문제 정의 → 데이터 소개 → EDA 주요 발견 → 모델 성능 → SHAP → 클러스터링 → 시뮬레이션 → 결론
- 슬라이드 당 1메시지 원칙: 핵심 그래프 1개 + 해석 3줄 이내
- 발표 시간 배분 고려 (10~15분 기준): 파트별 핵심만 압축 전달

[4단계: 최종 검토 및 제출 (4주차)]

- 보고서 오탈자, 수치 정합성 최종 확인
- 발표 리허설 진행 후 피드백 반영

- 코드/보고서/발표자료 패키지로 최종 제출

6. 종합 평가 및 결론

6-1. 진행 상황 평가

현재 프로젝트는 당초 계획 대비 분석 파트 전체(Part 1~7)를 완료한 상태로, 잔여 기간인 약 1개월은 결과 정리와 보고서/발표자료 완성에 집중할 수 있는 충분한 시간입니다. 프로젝트 목표에 설정된 6개 항목 중 5개가 달성 완료 상태이며, 최종 문서화만 남아 있어 전반적인 진행은 순조롭습니다.

6-2. 핵심 발견 요약

- 흡연 여부가 의료비를 결정하는 가장 강력한 단일 변수임을 다수의 분석 기법으로 일관되게 확인
- 나이 x 흡연, BMI x 흡연 등 상호작용 변수가 단순 원본 변수보다 훨씬 강한 예측력 보유
- GradientBoosting 계열 모델이 의료비 예측에서 일관되게 최우수 성능 달성
- 금연 효과는 고령+고BMI 흡연자에서 집중 — 개입 우선순위 선정의 정량적 근거 마련
- 분류 모델로 고비용 환자를 사전 식별 가능하여 보험 리스크 관리에 실질적 활용 가능

6-3. 향후 연구 방향

- 데이터 확장: 더 많은 샘플, 병력/직업/생활습관 등 추가 변수 확보 시 예측력 대폭 향상 기대
- 모델 고도화: XGBoost, LightGBM 등 추가 앙상블 기법 비교 검토 가능
- 공정성 분석: 성별, 지역별 예측 편향 여부 점검 (Fairness in ML 관점)
- 실제 적용: 보험사 실 데이터 연계 시 본 분석 프레임워크를 리스크 스크리닝 시스템으로 확장 가능

본 중간 보고서는 분석 코드 실행 결과 기반으로 작성되었으며, 최종 수치는 실행 환경에 따라 미세 차이가 있을 수 있습니다.