

의료비 예측 및 위험군 분류

머신러닝 기반 분석 프로젝트

중간 보고서

보고 일자 2025년 (중간 보고)

프로젝트 단계 Part 1~7 완료 / 잔여 약 1개월

사용 데이터 insurance.csv (1,338명)

분석 도구 Python, scikit-learn, SHAP, K-Means

* 본 보고서는 프로젝트 진행 현황을 점검하기 위한 중간 보고 문서입니다.* 본 보고서는 프로젝트 진행 현황을 점검하기 위한 중간 보고 문서입니다.

1. 프로젝트 개요 및 목표

1-1. 분석 배경 및 목적

본 프로젝트는 미국 건강보험 데이터(**insurance.csv**)를 기반으로 개인의 의료비를 예측하고, 고비용 위험군을 조기에 식별하는 머신러닝 모델을 개발하는 것을 목표로 합니다. 흡연, 나이, BMI 등 주요 변수가 의료비에 미치는 영향을 정량화하여 보험사와 의료 기관이 리스크를 사전에 관리할 수 있는 근거를 제공하고자 합니다.

1-2. 핵심 분석 목표

- 의료비(charges) 회귀 예측 모델 구축 및 최적 모델 선정
- 고비용 환자(상위 25%) 분류 모델 개발
- SHAP 기반 변수 중요도 해석 및 핵심 위험요인 도출
- K-Means 클러스터링을 통한 위험군 세분화
- 금연 시나리오 시뮬레이션을 통한 의료비 절감 효과 추정
- 흡연자 내부 고비용 세부 그룹 분석

2. 사용 데이터

2-1. 데이터셋 개요

구분	내용	비고
파일명	insurance.csv	Kaggle 공개 데이터셋
총 샘플 수	1,338명	결측치 없음

Train / Test	80% / 20%	(1,070 / 268명)
타깃 변수	charges (의료비, \$)	왜도 1.51, 우편포 분포

2-2. 원본 변수 (7개)

변수명	타입	범위/값	설명
age	수치형	18~64세	피보험자 나이
sex	범주형	male/female	성별
bmi	수치형	15.96~53.13	체질량지수
children	수치형	0~5명	부양 자녀 수
smoker	범주형	yes/no	흡연 여부 (핵심)
region	범주형	4개 지역	northeast/northwest/southeast/southwest
charges (Y)	수치형	\$1,122~\$63,770	연간 의료비 (예측 타깃)

3. 분석 진행 현황

3-1. 분석 단계별 완료 현황 및 추가 분석 이유

▶ Part 6: 이진 분류 모델 추가 이유

- 실무적 의사결정: **Part 1~5**의 회귀 모델은 의료비의 정확한 금액을 예측합니다. 하지만 보험사는 '이 환자가 고비용일 것인가?'라는 이진 의사결정이 더 중요합니다.
- 고비용 환자 식별: 상위 **25%**(약 **\$16,639** 이상)의 고비용 환자를 사전에 식별하면, 조기 개입(건강검진 강화, 케이스 관리, 예방 교육)으로 의료비를 효과적으로 관리할 수 있습니다.
- 모델 신뢰도 검증: **ROC-AUC**와 **PR Curve**는 모델의 구별 능력을 수치화하고, **Confusion Matrix**는 거짓 알람과 놓친 환자의 비율을 명확히 보여줍니다.
- 임계값 최적화: 분류 모델의 임계값을 조정하여 비용-편익을 최적화할 수 있습니다. 조기 개입 비용이 낮으면 민감도를 높이고, 비용이 높으면 정확도를 높입니다.

▶ Part 7: 흡연자 내부 세분화 추가 이유

- 고위험군 정밀화: **Part 4**의 **SHAP** 분석에서 흡연자는 의료비에 가장 강력한 영향을 미치는 그룹입니다. 하지만 흡연자 내에서도 큰 편차가 있으므로, 흡연자만 따로 모델링하여 '고비용 흡연자'와 '저비용 흡연자'를 구분할 필요가 있습니다.
- 맞춤형 중재 전략: 흡연자를 일괄 처리하지 않고 세분화된 그룹별로 다른 전략을 수립할 수 있습니다. 예: 고령+고BMI 흡연자 → 금연 프로그램 강화 | 저위험 흡연자 → 정기적 상담
- 개별화된 금연 효과 추정: 어떤 그룹이 금연할 경우 의료비 절감액이 가장 크고, 어느 그룹에 먼저 개입해야 하는지 정량적으로 파악할 수 있습니다.

- 보험료 차등화 근거: 흡연자 내 세분화는 더 정교한 위험도 평가와 차등화된 보험료 책정을 가능하게 하며, 개인별 의료비 절감 목표 설정에 직접 활용됩니다.

정리: **Part 6**은 '누가 위험한가?'를 판별하고, **Part 7**은 '위험한 사람 중 누구를 먼저 도울 것인가?'를 답하는 단계로, **Part 1~5**의 분석을 실제 의료비 관리 시스템으로 전환합니다.

3-2. 분석 단계별 완료 현황 (상세)

단계	파트	주요 내용	핵심 결과	상태
1	Part 1	탐색적 분석 (EDA)	흡연자 의료비 3~4배 높음	완료 ✓
2	Part 2	모델 학습 및 비교	GradientBoosting 최우수	완료 ✓
3	Part 3	하이퍼파라미터 튜닝	튜닝 후 성능 향상 확인	완료 ✓
4	Part 4	SHAP 변수 중요도	age_smoker, smoker_obese 핵심	완료 ✓
5	Part 5	K-Means 클러스터링	위험군 세분화 완료	완료 ✓
6	Part 6	이진 분류 모델	ROC-AUC 높은 성능	완료 ✓
7	Part 7	흡연자 내부 세분화	고령+비만 흡연자 우선 근거	완료 ✓

3-3. 주요 분석 결과 요약

[회귀 모델 성능 비교]

모델	R ²	RMSE	MAE	안정성	비고
LinearRegression	0.782	-	-	안정	
GradientBoosting	0.873	-	-	안정	최우수

[SHAP 분석 핵심 결과]

- **age_smoker** (나이 × 흡연): 의료비 예측에서 가장 중요한 변수 — 고령 흡연자일수록 의료비 급증
- **smoker_obese** (흡연 × 비만): 두 위험요인 복합 시 의료비에 추가적인 상승 효과
- **bmi_smoker** (BMI × 흡연): 흡연자 내에서도 BMI가 높을수록 의료비 증가
- 단순 **smoker** 변수보다 파생 상호작용 변수들이 더 강한 예측력을 가짐

[클러스터링 및 분류]

- **K-Means**: 최적 클러스터 수 탐색 완료. 고위험군(고령+흡연+비만 복합)과 저위험군 명확히 세분화
- 이진 분류: 고비용 환자(상위 25%, 약 \$16,639 이상) 판별 — 높은 ROC-AUC 달성

- 분류 모델은 회귀 모델과 상호 보완적으로 활용 가능 (리스크 스크리닝 + 정확한 금액 예측)

[금연 시뮬레이션]

- 274명 흡연자 대상, 흡연 관련 파생변수 일괄 0 처리 후 재예측
- 1인당 평균 절감 효과 정량 추정 완료 — 나이가 많고 BMI가 높은 흡연자일수록 절감 폭 더 큼
- 고령+비만 흡연자 우선 개입 시 의료비 절감 효과 극대화 가능

4. 프로젝트 목표 부합 점검

당초 설정한 분석 목표에 대비하여 현재까지 진행된 내용을 평가합니다.

목표	달성 내용	달성도
의료비 회귀 예측 모델	5개 모델 비교, 하이퍼파라미터 튜닝 완료. R^2 0.87+ 달성	달성 ✓
고비용 환자 분류 모델	이진 분류 모델 구축 완료, 높은 AUC 달성	달성 ✓
핵심 위험요인 도출	SHAP + 상호작용 변수 분석 완료	달성 ✓
위험군 세분화	K-Means + PCA 시각화 완료	달성 ✓
의료비 절감 효과 추정	금연 시뮬레이션으로 1인당 절감액 정량화 완료	달성 ✓
모델 해석 가능성 확보	SHAP waterfall로 개별 환자 의료비 원인 설명 가능	달성 ✓

4-1. 한계점 및 유의 사항

- 데이터 규모: 1,338명으로 실제 보험사 데이터 대비 소규모 — 일반화 한계 존재
- 변수 제한: 지역, 직업, 병력, 생활습관 등 추가 변수 부재로 설명력에 한계
- 시뮬레이션 한계: 금연 절감액은 모델 예측 기반 추정치이며, 실제 임상 결과와 차이 가능
- 모델 공정성: 성별, 지역 등에 따른 예측 편향 여부는 별도 점검 필요

5. 향후 일정 (잔여 약 1개월)

분석 코드는 모두 완성된 상태이며, 잔여 기간은 결과 정리, 보고서 고도화, 발표 준비에 집중합니다.

주차	기간	주요 작업	산출물
1주차	D+7	결과 수치 최종 확인 및 시각화 개선	검증 완료 수치표
2주차	D+8~D+14	최종 보고서 초안 작성	최종 보고서 초안
3주차	D+15~D+21	발표 자료(PPT) 제작	발표 슬라이드
4주차	D+22~최종일	최종 검토 및 제출	최종 제출본

6. 종합 평가 및 결론

6-1. 진행 상황 평가

현재 프로젝트는 당초 계획 대비 분석 파트 전체(Part 1~7)를 완료한 상태로, 잔여 기간인 약 1개월은 결과 정리와 보고서/발표자료 완성에 집중할 수 있는 충분한 시간입니다. 프로젝트 목표에 설정된 6개 항목 중 모두가 달성 완료 상태이며, 최종 문서화만 남아 있어 전반적인 진행은 순조롭습니다.

6-2. 핵심 발견 요약

- 흡연 여부가 의료비를 결정하는 가장 강력한 단일 변수임을 다수의 분석 기법으로 일관되게 확인
- 나이 × 흡연, BMI × 흡연 등 상호작용 변수가 단순 원본 변수보다 훨씬 강한 예측력 보유
- GradientBoosting 계열 모델이 의료비 예측에서 일관되게 최우수 성능 달성
- 금연 효과는 고령+고BMI 흡연자에서 집중 — 개입 우선순위 선정의 정량적 근거 마련
- 분류 모델로 고비용 환자를 사전 식별 가능하여 보험 리스크 관리에 실질적 활용 가능

6-3. 향후 연구 방향

- 데이터 확장: 더 많은 샘플, 병력/직업/생활습관 등 추가 변수 확보 시 예측력 대폭 향상 기대
- 모델 고도화: XGBoost, LightGBM 등 추가 앙상블 기법 비교 검토 가능
- 공정성 분석: 성별, 지역별 예측 편향 여부 점검 (Fairness in ML 관점)
- 실제 적용: 보험사 실 데이터 연계 시 본 분석 프레임워크를 리스크 스크리닝 시스템으로 확장 가능

본 중간 보고서는 분석 코드 실행 결과 기반으로 작성되었으며, 최종 수치는 실행 환경에 따라 미세 차이가 있을 수 있습니다.